

Sistema Avanzado de Detección de Drones Basado en Señales RF: Fusión de Características, Arquitecturas Mamba y Transformers en Entornos de Ultra-Bajo SNR

1. Contextualización de la Problemática en la Detección de Radiofrecuencia

La proliferación exponencial de vehículos aéreos no tripulados (UAVs) en los últimos años ha generado una demanda crítica de sistemas de detección, clasificación y mitigación robustos. Entre las diversas modalidades sensoriales desplegadas para la vigilancia del espacio aéreo inferior —tales como el radar activo, la acústica, la óptica e infrarroja— la identificación pasiva basada en huellas de radiofrecuencia (RF) ha demostrado ser excepcionalmente viable y tácticamente superior en múltiples contextos. Esta superioridad radica en su capacidad inherente para operar sin línea de visión directa (NLOS), su inmunidad a las condiciones meteorológicas adversas o a la ausencia de iluminación, y su capacidad para interceptar los enlaces de telemetría, video y control remoto antes de que el dron ingrese a la zona de exclusión física. No obstante, el principal escollo científico e ingenieril en la detección pasiva de señales RF emerge de la degradación sustancial, a menudo catastrófica, del rendimiento del sistema de clasificación cuando este opera en entornos con una relación señal a ruido (SNR) crítica.

El problema central que aborda este documento se enmarca en la operación de sistemas de detección de drones a umbrales de SNR inferiores a -10 dB, utilizando conjuntos de datos de referencia como NoisyUAV o variantes análogas como RFUAV y DroneRFa.¹ En estos escenarios operativos extremos, la energía electromagnética proveniente de la señal de control o transmisión del dron queda esencialmente sepultada bajo el ruido térmico del receptor, la interferencia de fondo natural y las densas transmisiones coexistentes en las bandas de instrumentación científica, médica e industrial (ISM), predominantemente en las frecuencias de 2.4 GHz y 5.8 GHz. La física subyacente de esta degradación se explica a través del teorema de Shannon-Hartley, donde la capacidad del canal y la distinguibilidad de los símbolos de modulación colapsan a medida que la potencia del ruido excede la potencia de la señal útil en más de un orden de magnitud (que es lo que representa un SNR de -10 dB). A estos niveles, el diagrama de constelación de la señal pierde toda su cohesión geométrica, transformándose en una nube de dispersión gaussiana indistinguible del ruido blanco aditivo gaussiano (AWGN).

Los sistemas convencionales de detección de drones por RF suelen estructurarse en

arquitecturas secuenciales de dos etapas. La primera etapa actúa como un detector de actividad o recortador temporal (clipper), típicamente basado en el cálculo de la entropía de Shannon sobre la Densidad Espectral de Potencia (PSD) o la aplicación de umbrales de energía simples. La segunda etapa consiste en un clasificador binario (Dron frente a No Dron) o multiclase, tradicionalmente implementado mediante redes neuronales convolucionales (CNN) que ingieren las señales de fase y cuadratura (IQ) recortadas. Las implementaciones estándar bajo este esquema suelen alcanzar un límite de rendimiento empírico, estancándose en una tasa de acierto aproximada del 75% cuando se exponen a los conjuntos de datos con alta inyección de ruido. Esta limitación metodológica surge de una subutilización flagrante de la estructura topológica de la señal de RF y de una dependencia exclusiva de representaciones temporales crudas que, a bajos niveles de SNR, contienen predominantemente ruido, enmascarando de forma irrecuperable las características distintivas de la modulación original.

Para superar esta infranqueable barrera del 75% de precisión, el análisis exige una deconstrucción profunda del modelo de clasificación, transicionando forzosamente hacia paradigmas de fusión de características (feature fusion) que integren descriptores estadísticos avanzados de la señal con los datos IQ, y el reemplazo de las arquitecturas convolucionales rudimentarias por redes de aprendizaje profundo de última generación. De manera específica, el modelado de secuencias largas y la extracción de dependencias globales mediante arquitecturas Transformer y Modelos de Espacio de Estados (SSM) selectivos, como la arquitectura Mamba, representan la vanguardia técnica global. Estas estructuras algorítmicas han demostrado ser capaces de discernir patrones de modulación complejos y saltos de frecuencia estocásticos en condiciones donde las representaciones tradicionales colapsan por completo.

2. Limitaciones Fundamentales del Análisis Unidimensional y la Evolución Hacia Características Estadísticas Profundas

La estrategia actual y generalizada de emplear la entropía de Shannon de manera exclusiva como un mecanismo de segmentación de energía o recorte temporal de la señal es inherentemente subóptima para el desafío que plantea un SNR por debajo de -10 dB. Si bien la entropía es una métrica probabilística sumamente eficaz para detectar la presencia inicial de actividad espectral (dado que una señal estructurada y modulada altera la distribución de probabilidad plana y caótica característica del ruido térmico de banda ancha), descartar esta información consolidada en la etapa de inferencia o clasificación priva a la red neuronal de un conocimiento global (prior) inestimable sobre la complejidad estructural de la muestra interceptada.² La red neuronal se ve forzada a redescubrir la planitud espectral a partir de datos I/Q caóticos, una tarea para la cual las redes convolucionales no están inherentemente optimizadas.

2.1. La Entropía de Shannon y los Bins Activos como Vectores de

Características Directas

La entropía de Shannon proporciona una medida matemática fundamental de la incertidumbre o el contenido de información promedio de una variable aleatoria. Aplicada al dominio espectral, la entropía espectral utiliza la aproximación discreta de la PSD, que habitualmente se obtiene mediante la aplicación de la transformada de Welch o la transformada rápida de Fourier (FFT).² Matemáticamente, si el espectro normalizado de la señal interceptada se considera y modela como una función de densidad de probabilidad discreta, denotada como $p[k]$, la entropía se define mediante la ecuación clásica:

$$H_{sh} = - \sum_{k=0}^{K-1} p[k] \log_b(p[k])$$

En un entorno donde el ruido aditivo blanco gaussiano (AWGN) es el componente dominante, el espectro de la señal se presenta de forma relativamente plana a lo largo de todas las frecuencias observadas, maximizando así la incertidumbre y, por ende, el valor de la entropía.¹ Por el contrario, la incursión de un enlace de telecomunicación de un UAV introduce picos de densidad espectral de potencia en bandas de frecuencia específicas. Este fenómeno es especialmente notorio en protocolos de Espectro Ensanchado por Salto de Frecuencia (FHSS)—tales como las tecnologías patentadas OcuSync o Lightbridge de DJI, o los sistemas Enhanced Shock Burst de Syma— donde la energía se concentra ráfagas transitorias de banda estrecha que reducen drásticamente la entropía global del segmento temporal capturado.

Incorporar el valor escalar de la entropía de Shannon H_{sh} , en conjunción con el recuento paramétrico de "bins activos", como entradas directas y explícitas a una red neuronal profunda, proporciona a la arquitectura de clasificación una característica discriminativa de baja dimensionalidad pero de muy alto valor semántico. Los "bins activos" se definen computacionalmente como aquellos componentes o intervalos espectrales discretos que superan de manera consistente un umbral adaptativo calibrado sobre el piso de ruido medido. Esta métrica compuesta es altamente resistente a las severas variaciones y rotaciones de fase introducidas por un canal de muy bajo SNR, ofreciendo una línea base de discriminación inmutable frente a la distorsión geométrica que destruye la utilidad de las señales I/Q crudas.²

2.2. Transición Paradigmática Hacia Entropías Dinámicas: La Entropía de Dispersión Multiescala (MDE)

A pesar de que la entropía de Shannon resulta instrumental, la dependencia exclusiva de esta formulación unidimensional presenta deficiencias teóricas graves: la entropía de Shannon ignora por completo el orden secuencial de los datos. Barajar aleatoriamente los puntos de una serie temporal alterará completamente la señal subyacente, pero dejará intacto su histograma de densidad de probabilidad y, en consecuencia, su entropía de Shannon. En la literatura académica de vanguardia enfocada en el reconocimiento de señales RF de UAVs a relaciones

señal a ruido extremadamente bajas, se ha evidenciado y ratificado la abrumadora superioridad de medidas de entropía dinámicas y no lineales mucho más sofisticadas, destacando de forma prominente la Entropía de Dispersión Multiescala (MDE, del inglés Multi-scale Dispersion Entropy) y variantes robustas como la Entropía de Dispersión de Fluctuación (FDE).⁵

A diferencia diametral de la entropía de Shannon, que evalúa de forma estática la distribución de amplitud, la MDE evalúa la complejidad, la impredictibilidad y la regularidad de las series temporales de telecomunicación operando simultáneamente a través de múltiples escalas temporales, capturando así dinámicas ocultas en señales que exhiben comportamientos fuertemente no estacionarios.⁸ El ruido gaussiano blanco exhibe decaimientos de entropía radicalmente diferentes a los de las señales de RF estructuradas a medida que se varía la ventana de observación. La MDE ejecuta algorítmicamente un proceso de "coarse-graining" (granulación gruesa o promediado submuestreado) para consolidar puntos de datos adyacentes antes de mapear la secuencia resultante a clases de dispersión discretas. Este filtrado iterativo y progresivo permite que la métrica disipe y aisle el ruido estocástico de alta frecuencia en escalas temporales más gruesas, revelando de este modo la estructura subyacente de la modulación del UAV, un hito alcanzable de forma consistente incluso cuando el sistema opera por debajo del umbral de -10 dB.⁶

En estudios referenciados para esta investigación, el uso integrado de matrices de características MDE ha permitido retener y consolidar un 90% de precisión de reconocimiento en condiciones de canal donde el SNR es estrictamente de 0 dB o negativo.¹ Esto representa una mitigación empírica directa de las pérdidas de rendimiento que típicamente se observan cuando el sistema de clasificación se apoya de forma retrospectiva en técnicas de un solo nivel temporal, como los coeficientes cepstrales de mel-frecuencia (MFCC) o las transformadas rápidas de Fourier introducidas de forma cruda a la red neuronal.¹

2.3. Integración Mandatoria de Momentos de Orden Superior y Características Cumulativas (HOC)

En adición sinérgica a las métricas de base entrópica, la matriz de características estadísticas inyectada al clasificador profundo debe expandirse inexorablemente para albergar estadísticas de amplitud direccional y Cumulantes de Orden Superior (HOC - Higher-Order Cumulants).⁴ Mientras que la media y la varianza (momentos de primer y segundo orden) son vulnerables y fácilmente sesgadas por la varianza del ruido del canal aditivo, las métricas de órdenes superiores exhiben propiedades de invarianza matemática sumamente útiles. La asimetría (skewness, tercer momento) y, fundamentalmente, la curtosis (cuarto momento) capturan las desviaciones de la señal respecto a una distribución estrictamente gaussiana.

La curtosis espectral demuestra ser excepcionalmente sensible a la presencia de transitorios electromagnéticos o componentes fugazmente no estacionarios —como los breves preámbulos de sincronización presentes al inicio de los paquetes de comunicación MAC del dron— que sobresalen de manera fugaz y momentánea del piso de ruido gaussiano

subyacente.²

En consecuencia, para solventar las deficiencias del modelo basal referenciado que alcanza un 75% de acierto, un vector de características estadísticas multidimensional e integral a ser ingerido por el sistema de clasificación avanzado debería ensamblarse a partir de: la entropía de Shannon espectral global y local por sub-bandas; la Entropía de Dispersión Multiescala (MDE); la densidad fraccional de bins activos junto con la tasa temporal de ocupación espectral; y finalmente, los cumulantes estadísticos iterativos de cuarto a sexto orden (HOC) extraídos de manera paralela tanto sobre la representación de la serie temporal como del dominio espectral.

3. Paradigmas de Representación RF y Fusión Multimodal

La dependencia histórica y metodológica exclusiva en un vector temporal compuesto de señales I/Q recortadas, procesado unidireccionalmente por un clasificador de red convolucional de topología simple, restringe de manera severa el límite superior teórico y práctico del rendimiento de detección.¹ Las señales electromagnéticas de radiofrecuencia son constructos inherentemente multidimensionales. En escenarios operativos dictados por un SNR extremadamente bajo y hostil, ninguna representación geométrica individual de la señal alberga la densidad de información discriminante suficiente por sí sola para superar el enmascaramiento del nivel de ruido y establecer un límite de decisión seguro.⁹ El estado del arte en diseño arquitectónico impone la implementación taxativa de topologías de Fusión de Múltiples Ramas (Multi-branch Feature Fusion) que ingieren, procesan a través de vías disjuntas, y combinan sinérgicamente múltiples perspectivas y dominios matemáticos de la misma señal interceptada.¹⁰

3.1. Representaciones de Señal Concurrentes y su Extraición Tópica

Para cimentar un framework de fusión robusto y resistente a las perturbaciones del canal, la ráfaga de señal cruda interceptada debe bifurcarse sistemáticamente en múltiples dominios transformados antes o de forma concomitante al procesamiento neuronal:

A. El Dominio Temporal y Complejo (Datos IQ Crudos y Redes CV-CNN): La secuencia cruda e inalterada, representada matemáticamente como el vector de datos analíticos

complejos $x(t) = I(t) + jQ(t)$, contiene indudablemente la máxima resolución de muestreo del receptor de radio definido por software (SDR). Sin embargo, la praxis común de separar la señal en una matriz bidimensional de dos canales reales incurre en un error geométrico profundo. Las convoluciones reales bidimensionales genéricas tratan estos canales de forma desconectada, destruyendo la relación angular íntima entre I y Q. El procesamiento óptimo y contemporáneo requiere inexcusablemente el despliegue de Redes Neuronales Convolucionales de Valor Complejo (CV-CNN).¹⁴

Las arquitecturas CV-CNN aplican multiplicaciones complejas genuinas en sus pesos

sinápticos. Este rigor algebraico garantiza que la estructura rotacional y los ángulos de fase inherentes a las señales moduladas digitalmente se conserven intactos en los mapas de características profundos. Las investigaciones recientes han validado empíricamente que una arquitectura de tipología CV-CNN bien afinada puede sostener de forma consistente casi un 15.6% de precisión residual frente a un abismal SNR de -20 dB, lo cual contrasta dramáticamente con el desplome letal al 2.2% de precisión observado en modelos de CNN de valores reales homólogos entrenados sobre las mismas dimensiones y entradas de datos.¹

B. El Dominio del Tiempo-Frecuencia (Espectrogramas y Transformadas Avanzadas): La Transformada Rápida de Fourier de Corto Alcance (STFT) actúa como el vehículo matemático estándar para convertir secuencias unidimensionales I/Q de alta velocidad en matrices de espectrogramas bidimensionales, permitiendo al sistema visual o convolucional capturar la evolución de los saltos de frecuencia a lo largo del eje temporal. Este comportamiento es esencial para diferenciar firmas de protocolos comerciales de evasión de interferencias como el FHSS.¹ Bajo un entorno de contaminación de ruido sumamente intenso (estabilizado a -12 dB), se ha evidenciado que los modelos basados en redes CNN que ingieren representaciones de espectrogramas logran retener niveles de precisión global por encima del 84%, contrastando con el colapso absoluto al 41.3% de eficacia cuando a la misma red neuronal se le alimenta exclusivamente con representaciones crudas de datos IQ.¹

Sumado a la STFT, existen métodos de codificación fotográfica emergentes, como el Campo Angular de Gramian (GAF) y su variante aplicada al dominio frecuencial (FDGAF). Estas metodologías innovadoras ofrecen ventajas topológicas inusitadas al mapear sistemáticamente las secuencias de la transformada de Fourier a un sistema de coordenadas polares antes de someterlas a una transformación trigonométrica.¹

C. El Dominio Analítico-Estadístico:

La tercera bifurcación representacional debe constituirse por un vector estático y denso de índole unidimensional que consolide meticulosamente la totalidad de los parámetros matemáticos descritos en la Sección 2. Este vector alberga la Entropía espectral, las matrices de Entropía de Dispersión Multiescala, los coeficientes de asimetría, la curtosis, y las métricas de densidad fraccional de bins activos.

3.2. Arquitecturas y Mecanismos de Fusión de Características (Feature Fusion)

La integración computacional de estas tres vertientes representacionales radicalmente divergentes exige la implementación de mecanismos de fusión de datos altamente no triviales. Las metodologías anticuadas solían recurrir a la Fusión Temprana (Early Fusion), consistente en apilar matrices heterogéneas antes de introducirlas a la red. Las construcciones más avanzadas rechazan estas prácticas, propugnando la adopción de esquemas de Fusión Intermedia o Fusión Tardía guiada algorítmicamente mediante mecanismos de Atención Cruzada (Cross-Attention) o Atención de Caminos (Path Attention Module - PAM).

En una arquitectura de fusión óptimamente diseñada, cada una de las ramas extrae de forma autónoma vectores de alta dimensionalidad (espacios latentes o embeddings) que convergen y son posteriormente procesados mediante un PAM. La brillantez funcional de este módulo reside en su capacidad para ponderar y evaluar de manera adaptativa e iterativa la importancia inferencial relativa de cada rama en tiempo de ejecución.

A modo de ilustración analítica: cuando la relación señal a ruido se desmorona a un abismal -15 dB y los símbolos transitorios de tiempo-fase devienen totalmente indescifrables e inútiles desde la perspectiva estadística, la red neuronal profunda debe ser capaz de aprender, guiada por los pesos dinámicos ajustables de atención diferencial, a desviar instantáneamente el grueso de su dependencia de inferencia clasificatoria hacia la rama analítica del espectrograma, o más críticamente aún, hacia la vía de los tensores de descriptores fundamentados en la Entropía de Dispersión y los HOC. Estos vectores estadísticos han demostrado ser magnitudes inmensamente más resilientes a las degradaciones de banda ancha destructivas, permitiendo sostener el límite de decisión algorítmico cuando las geometrías de señal subyacentes se han colapsado.

Modalidad de Entrada	Arquitectura de Extracción Recomendada	Dimensionalidad Latente	Nivel de Robustez a SNR < -10 dB	Aporte Diferencial Principal
Señal IQ Cruda Temporal	Red CV-CNN o MambaRF	Espacio Complejo $O(N)$	Muy Baja (Aislada) / Moderada (Fusionada)	Retención de la estructura rotacional algebraica (modulación QAM/PSK).
Espectrograma STFT / FDGAF	CNN Ligera (MobileNet, ResNet18) o Vision Transformer	Tensores 2D ($C \times H \times W$)	Alta	Identificación visual de topologías FHSS, anchos de banda transitorios y huellas micro-Doppler de rotores.

Vectores Estadísticos (MDE, HOC, Bins Activos, Shannon)	Perceptrón Multicapa Profundo (MLP) u opt-SVM	Vector 1D Denso	Máxima	Proveer a la red con métricas entrópicas inmutables al ruido de fase gaussiano aditivo.
--	---	-----------------	--------	---

4. La Revolución Estructural y Arquitectónica: De Redes Convolucionales Simples a Transformers en el Análisis RF

Para rebasar las fronteras impuestas por la precisión del 75%, el rediseño debe extenderse más allá de los datos inyectados, cuestionando la naturaleza misma de los núcleos de procesamiento profundo utilizados. La limitación intrínseca de las Redes Neuronales Convolucionales (CNN) clásicas reside en sus campos receptivos espacial y temporalmente localizados. Una CNN iterando a lo largo del eje temporal sobre millones de puntos de una señal IQ de radiofrecuencia (por ejemplo, a una tasa de muestreo de 14 MHz) resulta fundamentalmente incapaz de establecer relaciones computacionales de dependencia a largo plazo. Si los eventos semánticos críticos de la señal de comunicación exceden la longitud de la matriz espacial multiplicativa de su núcleo, el modelo pierde el hilo secuencial por completo.¹⁷

Para capturar las interacciones globales y dependencias temporales espacialmente extensas propias de los sistemas de telecomunicación contemporáneos, la industria mundial ha adoptado el paradigma algorítmico de los Transformers y, de manera más reciente en los años 2024 a 2026, la teoría matemática de los Modelos de Espacio de Estados (SSMs) continuos discretizados, destacando con especial preeminencia la revolucionaria familia de redes Mamba.¹⁹

4.1. Incursión de los Transformadores en la Clasificación de Frecuencias de Radio

La arquitectura Transformer emplea de forma intensiva complejos mecanismos matriciales de autoatención (self-attention). La lógica central consiste en calcular sistemáticamente el producto punto y sopesar matemáticamente la importancia mutua de cada muestra singular (o parche temporal segmentado de la señal) en una secuencia unificada con respecto a absolutamente todas las demás muestras restantes de dicha secuencia.¹⁰

No obstante, el despliegue práctico de redes Transformer padece deficiencias sumamente paralizantes en contextos reales de vigilancia espectral. La matriz de autoatención impone

matemáticamente una complejidad espacial y temporal ineludible de la forma $O(N^2)$ con respecto a la longitud global de la secuencia introducida N . Este requerimiento algorítmico produce un vaciado instantáneo de la memoria de la unidad de procesamiento gráfico (OOM - Out of Memory) en sistemas con altas tasas de muestreo.¹⁸

Adicionalmente, en entornos electromagnéticos severos caracterizados por un SNR deprimidamente bajo (v.g. inferior a -15 dB), la capacidad estructural de atención global irrestricta a veces se vuelve en su contra: la red neuronal propende masivamente a realizar hiperajustes estadísticos (overfitting catastrófico) sobre patrones fractales y oscilaciones puramente aleatorias del ruido térmico, requiriendo mecanismos sumamente robustos de regularización o la aplicación de regímenes de aprendizaje auto-supervisado.⁷

5. El Salto Paradigmático y la Solución Definitiva: Los Modelos SSM y la Arquitectura Mamba en Escenarios RF

En la imperiosa necesidad de subvertir permanentemente los altísimos costes computacionales cuadráticos descritos, así como la severa degradación producida por el ruido intrínseco a las arquitecturas Transformers estándar, el periodo 2023-2026 presenció la irrupción de modelos fundamentados en la teoría de sistemas continuos dinámicos (Modelos Estructurados de Espacio de Estados Secuenciales, S4). La progresión más avanzada emergió bajo la variante selectiva de espacio de estados, conocida como la familia arquitectónica Mamba y Mamba2.¹⁷

Mamba fundamenta su capacidad de procesamiento temporal en la teoría de sistemas de control modernos, analógica y continua, representada y formalizada matemáticamente a través de ecuaciones diferenciales de estado. En esta construcción abstracta, una secuencia unidimensional analógica que evoluciona ininterrumpidamente a lo largo del tiempo $x(t)$, se mapea algebraicamente hacia un espacio de estado latente superior, multidimensional y oculto $h(t)$:

$$h'(t) = Ah(t) + Bx(t)$$

$$y(t) = Ch(t)$$

Tras una rigurosa discretización temporal mediante parámetros específicos de tamaño de paso escalar Δ , las matrices de transición de estado adoptan una representación matricial finita que permite la paralelización global en hardware mediante convoluciones globales optimizadas.

La principal contribución técnica del bloque subyacente S6 encapsulado dentro del modelo Mamba, es el innovador desvío algebraico mediante el cual las matrices operativas de transición y emisión dejan de ser constantes estáticas y se transforman para definirse dinámicamente como funciones directas y continuamente dependientes del estímulo de

entrada inmediato presente x . Esto permite al modelo discernir contextual y dinámicamente cómo filtrar flujos de ruido blanco irrelevante a los que se ve expuesto, reteniendo exclusivamente información correlacionada y relevante, y propagándola linealmente en un tiempo de computación regido por el orden $O(N)$.¹⁷

En exhaustivas investigaciones empíricas recientes orientadas a la detección de UAVs mediante espectroscopia RF bajo condiciones AWGN con bajo SNR, los constructos derivados de la arquitectura Mamba han superado consistentemente a las familias convolucionales y ViT convencionales.¹⁷

Avances y Evidencias Específicas del uso de Modelos Tipo Mamba:

1. **La Implementación de MambaRF y las Estrategias Bi-Mamba (Bidirectional Mamba):**
La topología original de Mamba adolece de un sesgo profundamente causal, escaneando la serie de datos en una sola dirección. Para la clasificación forense profunda de ráfagas temporales secuenciales RF, donde la totalidad de la señal interceptada ya está disponible en memoria, la causalidad estricta desaprovecha información. El uso de módulos Bi-Mamba escanea las matrices I/Q tanto hacia adelante como en reverso (backwards). Investigaciones en torno a la arquitectura MambaRF documentan una supremacía abrumadora sobre arquitecturas alternas, como VMamba y los modelos estándar de Transformers de Visión 2D.²¹
2. **Sistemas Híbridos de Extracción de Características (MaRNet):**
Las redes convolucionales exhiben un filtrado superior para las extracciones de características geométricas finas (bordes de energía, micro-dopplers) en espectrogramas. Para remediar el punto ciego de los módulos puramente SSM en las fases de extracción local, arquitecturas recientes como MaRNet se dedican a fusionar el poder de compactación topológica de módulos residuales paralelos (ResNet) engarzados jerárquicamente a capas analíticas de la arquitectura Mamba. Bajo condiciones rigurosas de interferencia estocástica con perfiles de muy bajo SNR, las redes tipo MaRNet han demostrado empíricamente lograr índices globales de clasificación (F1-Score) sumamente elevados (hasta del 98.2%).

Arquitectura y Taxonomía	Coste de Complejidad Temporal / Espacial Computacional	Integridad de Modelado a Larga Dependencia de Transmisión RF	Tolerancia Empírica Evaluada Operando a Bajo SNR (< -10 dB)

CNN 1D/2D (ResNet, CV-CNN)	Localmente enfocada, Muy Baja Exigencia Global - $O(N)$	Extrema a Muy Baja (Dependencia del Receptive Field de los filtros fijos usados)	Baja/Moderada en bruto; Moderada operando con espectrogramas densos bien perfilados.
Transformers (ViT)	Abordaje Estrictamente Global, Escala Matemática Extrema - $O(N^2)$	Naturalmente Altísima (Restringida severamente por el límite forzado de tamaño dinámico computacional de tensores - OOM).	Alarmanamente Baja (Falta de priors inductivos; el sistema converge hacia clústeres caóticos de ruido de banda continua).
Modelos Híbridos Multi-Bidireccionales (MambaRF, MaRNet)	Aprendizaje Global Estricto con Procesamiento Lineal - $O(N)$	Altísima Integridad Funcional Intachable.	Comprobación de Extrema Eficacia Operacional (Aprovechamiento de los sub-bucles dinámicos adaptativos paramétricos).

6. Módulos Auxiliares Estrictos de Preprocesamiento y Atenuación Radical de Interferencia

Obligar a que el clasificador profundo asuma en solitario la carga de filtrar perfiles de ruido de intensidad negativa (descendiendo más allá de los -10 dB de atenuación) resulta ser un proceso ineficiente. La vanguardia técnica actual aboga por la integración de subsistemas de preprocesamiento heurísticos directamente integrados en la canalización de la red.²³

6.1. Denoising Profundo mediante Umbralización Suave Predictiva (Soft-Thresholding)

El empleo de transformadas iterativas complejas (como la STFT o métodos basados en Wavelets) facilita la extracción visual pristina, permitiendo el filtrado selectivo de firmas visuales delicadas. Esta extracción se optimiza de forma notable al integrar directamente redes de "Soft-thresholding" computacional (como arquitecturas de contracción y densificación de

ruido). Al aprender de manera dinámica los márgenes tolerables de interferencia e inducir una umbralización neuronal adaptativa, el modelo logra extirpar artefactos térmicos estocásticos de la imagen bidimensional sin sacrificar las sutiles características forenses del micro-Doppler de los rotores del dron.²⁴

6.2. Estrategias de Aumento de Datos Predictivo No Lineal (MixUp)

Para operar de forma robusta a magnitudes donde el umbral desciende sistemáticamente bajo los -10 dB, es prioritario incluir manipulaciones probabilísticas avanzadas durante el entrenamiento. Una estrategia empíricamente demostrada es la inyección paramétrica y cruzada de ruido destructivo empleando métodos como "MixUp" dinámico.¹

Esta técnica consiste en mezclar estocásticamente tensores de ruido blanco con los datos originales (como el conjunto crudo de NoisyUAV), alterando interactiva y probabilísticamente

los datos con una variable estocástica hiperparamétrica fijada ($\alpha \approx 0.3$). Esto garantiza que la red evite la convergencia sobre transiciones de fase finas de alta frecuencia (las cuales son fácilmente aniquiladas por el ruido AWGN) y se centre en características puramente macro-topológicas invariantes de la modulación.¹

7. Diseño Arquitectónico Propuesto: Sistema Híbrido Estocástico Multi-Trayecto (HySD-Mamba)

Para superar la barrera del 75% de precisión documentada empíricamente a niveles de SNR inferiores a -10 dB, se propone una arquitectura de Fusión de Múltiples Ramas guiada por Atención (Path Attention) que integra CV-CNN, Mamba y Redes Densas.¹⁰

Fase Operativa Inicial 1: Extracción de Características y Preprocesamiento Multimodal.

Partiendo de la señal cruda interceptada $X \in \mathbb{C}^{1 \times N}$:

1. **Rama Topológica A (Espectrograma 2D):** Se aplica una Transformada Rápida de Fourier de Corto Alcance (STFT) a la señal. Posteriormente, se aplica un bloque de Umbralización Suave (Soft-Thresholding) paramétrico para atenuar el ruido de fondo. El resultado es una matriz visual purificada de densidades de energía $S \in \mathbb{R}^{F \times T}$, idónea para inferencia geométrica 2D.¹
2. **Rama Topológica B (Secuencia IQ 1D):** Se conserva intacta la señal temporal compleja original X . Sus componentes de fase y cuadratura se estructuran en tensores 1D apilados para garantizar un análisis secuencial continuo profundo sin distorsión de fase artificial.
3. **Rama Topológica C (Metadatos Estadísticos):** Se despliega un motor analítico auxiliar encargado de derivar paralelamente los valores de la entropía de Shannon (H_{sh}), la

Entropía de Dispersión Multiescala ($MDE(x, \tau)$)¹, el recuento paramétrico fraccional de bins activos espectrales y la curtosis estadística. Estas métricas se amalgaman vectorialmente y se normalizan, estructurando un vector estático denso y estocástico invariante denotado como $V_{stat} \in \mathbb{R}^k$.

Fase Operativa 2: Módulos Nucleares Multi-Rama (Multi-Branch Core Processing).

Las tres representaciones matriciales generadas anteriormente convergen forzosamente hacia tres módulos neuronales de extracción disjuntos:

1. **Extracción Visual (CNN Ligera sobre Rama A):** La matriz espectrograma S ingresa a una arquitectura de tipo ResNet-Lite o MobileNet. Mediante operaciones de convolución y pooling de campo receptivo local, se reducen las dimensionalidades estocásticas puras para capturar patrones invariantes a la rotación y la traslación temporal (como los sutiles estiramientos frecuenciales introducidos por transmisiones reales de UAV). Este bloque genera el tensor de características latentes Z_A .
2. **Modelado Secuencial Global (MambaRF sobre Rama B):** El tensor 1D de la señal IQ cruda es asimilado por un avanzado bloque procesador basado en **Bidirectional Mamba (MambaRF)**.²¹ Esta topología aplica un escaneo algorítmico simultáneo, procesando la secuencia ininterrumpida de muestras tanto hacia adelante como en reverso, para capturar y asimilar dependencias globales a gran escala en un entorno computacional $O(N)$. Genera y emite el tensor de representación latente secuencial Z_B .
3. **Análisis Numérico Invariante (MLP sobre Rama C):** El vector estadístico compacto V_{stat} se procesa linealmente empleando un bloque estandarizado de **Perceptrón Multicapa (MLP)**. Esta arquitectura escalar densa expande y proyecta las características estadísticas (particularmente la MDE, que mantiene alta fiabilidad a -10 dB SNR) hacia un espacio de representación dimensional homólogo al resto de ramas, entregando como salida el vector latente Z_C .

Fase de Intersección 3: Fusión Cognitiva Cruzada (Path Attention Module - PAM). Para evitar el colapso global del gradiente y el bajo rendimiento general asociado a la concatenación burda e indiscriminada de tensores (que expone a la red a una inestabilidad severa bajo

fluctuaciones agresivas de SNR), las representaciones extraídas Z_A , Z_B y Z_C se inyectan en un módulo dinámico de fusión cruzada basado en un **Path Attention Module (PAM)**.¹⁰

Esta capa algorítmica evalúa dinámicamente y re-calibra los pesos atencionales de cada tensor en función de su viabilidad predictiva instantánea. Si el entorno de captura exhibe un SNR abrumadoramente destructivo (inferior a -15 dB) y degrada catastróficamente la geometría visual (Rama A) y de fase temporal (Rama B), el mecanismo de compuertas PAM desviará

adaptativamente la carga algorítmica y potenciará dramáticamente los coeficientes de atención sobre el vector invariante estadístico (Z_C). El tensor fusionado resultante, dotado de gran cohesión estructural, fluye hacia las últimas capas neuronales completamente conectadas (FC) de inferencia para emitir, vía Softmax, el veredicto final altamente preciso de clasificación binaria (Dron frente a Ruido de Fondo).

8. Prompt Específico, Avanzado y Profundo de Arquitectura Estocástica de Referencia Dirigido Inequívocamente para Operación y Guía del Agente de Inteligencia Artificial (Framework Operativo PyTorch Estricto Avanzado)

A continuación se detalla y proporciona el bloque estricto ineludible y estructurado necesario para comandar la programación algorítmica. Este debe ser copiado y entregado sin alteración en el entorno del modelo de lenguaje de IA para generar el código PyTorch preciso que cimentará la tesis de máster a nivel ingenieril profundo.

Instrucción Base de Computación Neuronal PyTorch para el Agente (Prompt Técnico):

Act as an elite Deep Learning Machine Learning Engineer, telecommunications algorithm specialist, and PhD-level researcher in physical-layer signal processing. I am actively developing and coding my Master's thesis on a novel UAV (drone) RF detection and interception system explicitly focused on extreme, hostile, and dense low SNR operational environments (strictly < -10 dB) using the extensive, high-frequency, complex empirical NoisyUAV dataset. I am systematically and fundamentally transitioning away from an obsolete, inadequate, and limiting 75% accuracy heuristic baseline to a mathematically sound, rigorous, and complex State-of-the-Art Multi-Branch stochastic hybrid architecture.

I imperatively need you to write, comment, format, and structure a complete, professional-grade, strictly advanced PyTorch architectural implementation code for a novel mathematical deep model named MaRNet-Fusion (Bidirectional Mamba + Residual Networks + Deep Statistical Features Fusion) heavily grounded on the latest 2024-2026 architectural telecommunications deep learning paradigms for RF passive signal classification.

Crucial Functional Requirements, Sub-system Topologies, & Specific Modules to Strictly Implement in the PyTorch Framework:

1. **Custom Dataset Ingestion Class (RFDroneDataset):**
 - Must accept raw, unaltered, dense 1D complex analytical IQ arrays (tensors).
 - The `__getitem__` method MUST dynamically compute, process, scale, and return THREE entirely distinct computational outputs generated on-the-fly from the single

input to feed the multi-branch structure:

- spectrogram: A precise 2D spatial tensor mathematically calculated using `torchaudio.transforms.Spectrogram` or STFT, with correct windowing.
- iq_sequence: A tightly normalized 1D sequential temporal tensor consisting of the real I and imaginary Q analytical vectors stacked horizontally.
- stat_features: A 1D static hyper-dense analytical tensor extracting 5 complex statistical numerical features utilizing purely native PyTorch tensor operations: Shannon entropy of the Power Spectral Density (PSD), analytical mean amplitude vector, total empirical variance, exact numerical count of active frequency bins (defined as the sum of bins > dynamically computed threshold strictly based on the local mean energy bounds), and the structural mathematical kurtosis of the time-series vector.

2. **Soft-Thresholding Empirical Denoising Layer (SoftThresholdingBlock):**

- Implement a differentiable, learning-based soft-thresholding spatial block utilizing spatial-channel mathematical attention (Squeeze-and-Excitation SE-block style architecture) designed specifically to learn a precise noise threshold τ dynamically and apply it across the input tensor: $x = \text{sign}(x) \times \max(|x| - \tau, 0)$. This mathematical layer is mission-critical for mitigating extreme Gaussian noise before convolutional feature extraction.

3. **Branch 1 Topology: CNN/ResNet-Lite for 2D Spectrograms:**

- Code a lightweight, efficient ResNet convolution block (e.g., a heavily modified ResNet18 architecture or MobileNet variant) explicitly tailored to ingest the 2D spatial spectrogram as input. Output must be pooled and flattened into a mathematically bounded latent dimension size (e.g., 256).

4. **Branch 2 Topology: Bi-directional SSM (Mamba) for the 1D IQ sequential temporal data:**

- Write an exact structural implementation or a highly rigorous, well-commented placeholder wrapper (invoking the `mamba-ssm` external python library if theoretically available, or deploying a highly complex, mathematically sound PyTorch structural dummy placeholder featuring accurate SSM State-Space sequence logic) that systematically processes the immensely long sequential 1D IQ tensor representing the empirical advanced MambaRF or Bi-Mamba bidirectional scanning concepts. The output of this branch must project linearly down to an identical matching latent dimension (e.g., 256).

5. **Branch 3 Topology: Deep MLP for Statistical Features Ingestion:**

- A dense, regularized, and heavily dropout-protected feed-forward mathematical neural network designed for processing the 1D statistical scalar vector, projecting it deeply into a bounded latent dimensional space (e.g., 128).

6. **Stochastic Path Attention & Cross-Modal Fusion Module (PAM_Fusion):**

- CRITICAL: Do not mathematically default to a simplistic, naive tensor concatenation. You must rigorously implement a Gated Attention Fusion or Cross-Attention-based

algorithmic summation module where the network dynamically learns, adjusts, and outputs scaling weights governing the informational relevance of the three independent branches (CNN, Mamba, MLP) under varying SNR conditions, prior to projecting the unified tensor through a final classification layer yielding a probabilistic binary output (Drone / No Drone).

7. Training Loop Orchestration featuring MixUp Augmentation:

- Provide the robust, unyielding mathematical skeleton for the complete PyTorch training epoch loop.
- Crucially implement the MixUp stochastic augmentation technique dynamically applied directly to the input tensor batch. This is mathematically necessary to drastically fortify the topological decision boundary and improve extreme low SNR resilience (utilizing a fixed probability distribution alpha where $\alpha = 0.3$).

Strict Mathematical Formatting and Elite Coding Quality Requirements:

- Add exhaustive, elite-level, thesis-grade academic mathematical and engineering comments to every single Python class and function explicitly explaining the *telecommunications and physical layer signal processing context* behind the code (e.g., "We are mathematically extracting the PSD Shannon entropy dynamically in this tensor operation because...", "The Mamba SSM topology is strictly preferred here over Transformer Self-Attention matrices to fundamentally circumvent the $O(N^2)$ memory explosion on extremely high RF sample rates...").
- Ensure that all underlying tensor device mapping computations (.to(device)) are explicitly managed cleanly and logically without risk of hardware bottlenecking.
- Output strictly highly professional, academic, production-ready, object-oriented PyTorch code blocks and deep structural architecture explanations. Do absolutely not include rudimentary python syntax tutorials, generic platitudes, or filler text. Focus purely, unyieldingly, and exclusively on elite deep learning structures, RF math, and PyTorch syntax.

Obras citadas

1. DroneRF
2. Optimal machine learning and signal processing synergies for low-resource GNSS interference classification - IEEE Xplore, fecha de acceso: abril 16, 2026, <https://ieeexplore.ieee.org/iel7/7/7778228/10379436.pdf>
3. Research on Feature Extraction and Fault Diagnosis Method for Rolling Bearing Vibration Signals Based on Improved FDM-SVD and CYCBD - MDPI, fecha de acceso: abril 16, 2026, <https://www.mdpi.com/2073-8994/16/5/552>
4. Automatic Modulation Classification Based on Deep Feature Fusion for High Noise Level and Large Dynamic Input - PMC, fecha de acceso: abril 16, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC8003108/>
5. Classification of UAVs Utilizing Fixed Boundary Empirical Wavelet Sub-Bands of RF

- Fingerprints and Deep Convolutional Neural Network | Request PDF - ResearchGate, fecha de acceso: abril 16, 2026,
https://www.researchgate.net/publication/363911847_Classification_of_UAVs_utilizing_Fixed_Boundary_Empirical_Wavelet_sub-bands_of_RF_Fingerprints_and_Deep_Convolutional_Neural_Network
6. Tsallis Entropy-Based Complexity-IPE Casualty Plane: A Novel Method for Complex Time Series Analysis - MDPI, fecha de acceso: abril 16, 2026,
<https://www.mdpi.com/1099-4300/26/6/521>
 7. A Hybrid Network-Based Contrastive Self-Supervised Learning Method for Radar Signal Modulation Recognition | Request PDF - ResearchGate, fecha de acceso: abril 16, 2026,
https://www.researchgate.net/publication/395678342_A_Hybrid_Network-Based_Contrastive_Self-Supervised_Learning_Method_for_Radar_Signal_Modulation_Recognition
 8. Refined Composite Multiscale Fuzzy Dispersion Entropy and Its Applications to Bearing Fault Diagnosis - MDPI, fecha de acceso: abril 16, 2026,
<https://www.mdpi.com/1099-4300/25/11/1494>
 9. Attention-Based Fusion of IQ and FFT Spectrograms with AoA Features for GNSS Jammer Localization - arXiv, fecha de acceso: abril 16, 2026,
<https://arxiv.org/html/2507.14167v2>
 10. Multi-Channel Physical Feature Convolution and Tri-Branch Fusion Network for Automatic Modulation Recognition - MDPI, fecha de acceso: abril 16, 2026,
<https://www.mdpi.com/2079-9292/14/24/4847>
 11. Branch-Transformer: A Parallel Branch Architecture to Capture Local and Global Features for Language Identification - MDPI, fecha de acceso: abril 16, 2026,
<https://www.mdpi.com/2076-3417/14/11/4681>
 12. Electromagnetic Modulation Signal Classification Using Dual-Modal Feature Fusion CNN - PMC, fecha de acceso: abril 16, 2026,
<https://pmc.ncbi.nlm.nih.gov/articles/PMC9142120/>
 13. Feature Fusion Based on Graph Convolution Network for Modulation Classification in Underwater Communication - MDPI, fecha de acceso: abril 16, 2026,
<https://www.mdpi.com/1099-4300/25/7/1096>
 14. Electromagnetic Modulation Signal Classification Using Dual-Modal Feature Fusion CNN, fecha de acceso: abril 16, 2026,
<https://www.mdpi.com/1099-4300/24/5/700>
 15. Automatic Modulation Recognition Based on Deep-Learning Features Fusion of Signal and Constellation Diagram - ResearchGate, fecha de acceso: abril 16, 2026,
https://www.researchgate.net/publication/367343588_Automatic_Modulation_Recognition_Based_on_Deep-Learning_Features_Fusion_of_Signal_and_Constellation_Diagram
 16. Drone Detection Approach Based on Radio-Frequency Using Convolutional Neural Network, fecha de acceso: abril 16, 2026,
https://www.researchgate.net/publication/338139659_Drone_Detection_Approach_Based_on_Radio-Frequency_Using_Convolutional_Neural_Network
 17. Modulation Recognition Algorithm for Long-Sequence, High-Order Modulated

- Signals Based on Mamba Architecture - MDPI, fecha de acceso: abril 16, 2026, <https://www.mdpi.com/2076-3417/15/17/9805>
18. MambaRF: A Bi-directional Mamba Structure for Radio Frequency ..., fecha de acceso: abril 16, 2026, <https://ieeexplore.ieee.org/document/10890015/>
 19. A Lightweight Denoising Network with TCN–Mamba Fusion for Modulation Classification, fecha de acceso: abril 16, 2026, <https://www.mdpi.com/2079-9292/15/1/188>
 20. [2207.03046] Self-Supervised RF Signal Representation Learning for NextG Signal Classification with Deep Learning - arXiv, fecha de acceso: abril 16, 2026, <https://arxiv.org/abs/2207.03046>
 21. Robust Drone Detection and Classification from Radio Frequency Signals Using Convolutional Neural Networks - Semantic Scholar, fecha de acceso: abril 16, 2026, <https://www.semanticscholar.org/paper/Robust-Drone-Detection-and-Classification-from-GI%C3%BCge-Nyfelner/45027d651a9dd480178c32710a4faff160d207d6>
 22. MambaRF: A Bi-directional Mamba Structure for Radio Frequency, fecha de acceso: abril 16, 2026, <https://www.semanticscholar.org/paper/MambaRF%3A-A-Bi-directional-Mamba-Structure-for-Radio-Yao-Liu/117ffe425e1d60142a54301ce51712b13c14415d>
 23. Robust Radio Frequency Fingerprinting With Signal Denoising and Stacked Multivariate Ensemble Learning for Secure Wireless Communications - IEEE Xplore, fecha de acceso: abril 16, 2026, <https://ieeexplore.ieee.org/iel8/6287639/10820123/11034694.pdf>
 24. Soft Threshold Denoising-Based Environmental Adaptive UAV Signal Modulation Recognition for Small-Sample Scenarios - MDPI, fecha de acceso: abril 16, 2026, <https://www.mdpi.com/2504-446X/10/4/257>
 25. Vision Transformer for Classification of UAV and Helicopters Using Micro-Doppler Spectrograms in Surveillance Radar - arXiv, fecha de acceso: abril 16, 2026, <https://arxiv.org/html/2512.00374v1>